


.NET

# Extendiendo las capacidades de la IA con RAG en .Net 10

Ing. Marcos Polischuk  
Software architect



# Algunos Conceptos



## LLM

Un modelo de lenguaje extenso (LLM) es un modelo estadístico de lenguaje, entrenado con una gran cantidad de datos, que se puede usar para generar y traducir texto y otros contenidos, así como realizar otras tareas de procesamiento de lenguaje natural (PLN).

**Claude, Deepseek, Gemini, GPT, etc**



## Capacidades principales

Los LLM son una tecnología clave en la que se basan los chatbots inteligentes y otras aplicaciones. El objetivo es crear bots que puedan responder a las preguntas de los usuarios en diversos contextos mediante referencias cruzadas de fuentes de conocimiento autorizadas.



## Limitaciones

Desafortunadamente, la naturaleza de la tecnología del LLM agrega imprevisibilidad en las respuestas del LLM. Además, los datos de entrenamiento del LLM son estáticos y agregan una fecha límite en los conocimientos que tienen.

# El problema: Conocimiento fragmentado, costes crecientes


## Múltiples fuentes desfragmentadas

- Información dispersa por distintos sistemas
- Información desactualizada
- Imposibilidad de tracking
- Respuestas inexactas debido a confusiones terminológicas

## Impacto en las métricas

- **High AHT:** Los agentes pierden tiempo buscando.
- **Low FCR:** Información incompleta produce callbacks
- **Stressed CSAT:** Respuestas lentas e inconsistentes
- **Compliance risk:** Sin rastro de citaciones


La fragmentación del conocimiento genera respuestas inconsistentes entre los agentes, complica la incorporación de nuevos datos y hace prácticamente imposible la escalabilidad por temporadas. Cada consulta se convierte en una investigación manual a través de sistemas desconectados.




# RAG al rescate!

La generación aumentada por recuperación (**RAG** - **R**etrieval **A**ugmented **G**eneration) es un framework de IA que combina las ventajas de los sistemas tradicionales de recuperación de información (como la búsqueda y las bases de datos) con las capacidades de los LLM.

Al combinar tus datos y el conocimiento del mundo con las habilidades lingüísticas de los LLMs, la generación fundamentada es **más precisa, actualizada y relevante** para tus necesidades específicas.



# RAG al rescate!



# Ejemplo de escenario de caso de uso

## Sistema de tracking de pedidos



### Cuando llega?

Requiere verificar los plazos de la póliza estándar con los datos de seguimiento en tiempo real del transportista para obtener horas de llegada estimadas precisas, no estimaciones genéricas.



### Llegó dañado

Debe hacer referencia a los plazos de notificación establecidos en las políticas, los requisitos de evidencia (carga de fotos) y los flujos de trabajo específicos de reemplazo vs reembolso.



### Cambié la dirección

Incluye restricciones específicas del operador, límites de tiempo, posibles tarifas y limitaciones del sistema; todo ello documentado por separado.



### Demoras en transporte

Se necesita una función de búsqueda de SLA por operador, protocolos de comunicación proactivos y posibles políticas de compensación basadas en la gravedad de la demora.

**Cada escenario demuestra la amplitud de las dependencias de datos y la complejidad a la que se enfrentan los agentes cuando la información reside en múltiples sistemas no conectados.**

# Propuesta de solución para el escenario

## **App que extiende soporte de LLM con RAG**

### **Orquestación de múltiples fuentes**

Realiza consultas inteligentes en paralelo usando políticas de PDF, información de registros en bases de datos SQL y API externa de seguimiento.


### **Procesamiento usando Gemini**

Sintetiza la evidencia recuperada en respuestas coherentes y contextuales.

### **Respuestas trazables**

Devuelve respuestas coherentes con citas verificables para cada hecho.

**Un asistente de IA que reúne fuentes de conocimiento fragmentadas, elimina la búsqueda manual y ofrece respuestas fiables con total trazabilidad, todo ello a través de una única interfaz intuitiva.**



# SmartSupport POC demo



# ¿Preguntas?



# Muchas gracias



@markfab182



/marcos-fabian-polischuk



<https://github.com/MPolischuk/smartsupport>